

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
BỘ MÔN PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH



PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH
ASSIGNMENT 02

Giảng viên hướng dẫn	: TRẦN ĐÌNH QUẾ
Họ và tên sinh viên	: NGUYỄN NGỌC HOÀNG NAM
Mã sinh viên	: B23DCCN585
Lớp	: D23CQCN11-B
Nhóm	: 05

Hà Nội – 2026

MỤC LỤC

MỤC LỤC.....	2
CHƯƠNG 1. TỔNG QUAN VÀ KIẾN TRÚC HỆ THỐNG.....	3
1.1. Đặt vấn đề.....	3
1.2. Phương pháp luận phát triển.....	3
1.3. Kiến trúc Hệ thống (System Architecture).....	3
CHƯƠNG 2. ỨNG DỤNG 1 - CHẨN ĐOÁN RỦI RO TIỂU ĐƯỜNG (Y TẾ).....	4
2.1. Phân tích Dữ liệu Khám phá (EDA).....	4
2.2. Kỹ thuật Tiền xử lý và Mô hình hóa.....	4
2.3. Đánh giá Mô hình (Evaluation).....	4
CHƯƠNG 3. ỨNG DỤNG 2 - ĐỊNH GIÁ BẤT ĐỘNG SẢN (TÀI CHÍNH).....	5
3.1. Phân tích Dữ liệu và Xử lý Nhiễu (Outliers).....	5
3.2. Mô hình hóa với Random Forest Regressor.....	5
3.3. Trích xuất Khoảng tin cậy (Confidence Interval).....	5
CHƯƠNG 4. ỨNG DỤNG 3 - PHÂN TÍCH HÀNH VI E-COMMERCE (THƯỜNG MẠI).....	6
4.1. Đặc trưng Dữ liệu.....	6
4.2. Bài toán Phân loại Đa lớp (Multiclass Classification).....	6
4.3. Đánh giá bằng Weighted F1-Score.....	6
CHƯƠNG 5. SO SÁNH CHÉO 3 ỨNG DỤNG (CROSS-APPLICATION COMPARISON).....	7
Phân tích chuyên sâu các điểm khác biệt.....	7
5.1. Khác biệt về Cấu trúc dữ liệu (Data Structure).....	7
5.2. Khác biệt về Cách biểu diễn (Representation).....	8
5.3. Khác biệt về Phương pháp Tiền xử lý (Preprocessing).....	8
5.4. Sự khác nhau trong việc chọn Thuộc đo đánh giá (Evaluation Metrics).....	8
CHƯƠNG 6. KỸ THUẬT TRIỂN KHAI VÀ XAI (EXPLAINABLE AI).....	10
6.1. Ngăn chặn Rò rỉ Dữ liệu (Data Leakage Prevention).....	10
6.2. Suy luận dựa trên ca mẫu (Case-based Reasoning) & XAI.....	10
6.3. Triển khai Giao diện và Demo Đa nền tảng (Responsive UI).....	10
1. ỨNG DỤNG 1 - CHẨN ĐOÁN RỦI RO TIỂU ĐƯỜNG.....	10
2. ỨNG DỤNG 2 - ĐỊNH GIÁ BẤT ĐỘNG SẢN.....	11
3. ỨNG DỤNG 3 - PHÂN TÍCH HÀNH VI E-COMMERCE	12
6.4. Quản lý Mã nguồn (Source Code).....	13

CHƯƠNG 1. TỔNG QUAN VÀ KIẾN TRÚC HỆ THỐNG

1.1. Đặt vấn đề

Sự bùng nổ của dữ liệu trong kỷ nguyên số đặt ra yêu cầu cấp thiết về việc xây dựng các hệ thống hỗ trợ ra quyết định thông minh. Thay vì phát triển các mô hình đơn lẻ, đề án này hướng tới việc xây dựng một hệ thống đa nhiệm (Multi-domain), có khả năng giải quyết đồng thời ba bài toán thực tiễn: chẩn đoán y tế, định giá tài sản và phân tích hành vi người dùng.

1.2. Phương pháp luận phát triển

Dự án được thực hiện tuân thủ nghiêm ngặt theo quy trình chuẩn CRISP-DM (Cross-Industry Standard Process for Data Mining), bao gồm 6 giai đoạn: Hiểu nghiệp vụ (Business Understanding) → Hiểu dữ liệu (Data Understanding) → Tiền xử lý (Data Preparation) → Mô hình hóa (Modeling) → Đánh giá (Evaluation) → Triển khai (Deployment).

1.3. Kiến trúc Hệ thống (System Architecture)

Hệ thống được thiết kế theo mô hình Client-Server với kiến trúc Monolithic:

1.3.1. Backend (Server-side): Sử dụng **FastAPI** (Python) để xây dựng RESTful API. Lựa chọn FastAPI giúp hệ thống đạt hiệu năng cao nhờ cơ chế xử lý bất đồng bộ (Asynchronous), đồng thời tích hợp sẵn **Pydantic** để xác thực kiểu dữ liệu (Data Validation) ngay từ đầu vào.

1.3.2. Frontend (Client-side): Giao diện được phát triển bằng HTML5, CSS3 và Javascript thuần, kết hợp framework **Bootstrap 5**. Việc áp dụng Grid System giúp giao diện Responsive, hiển thị mượt mà trên cả trình duyệt Web và thiết bị Mobile (Điện thoại/Tablet) mà không cần lập trình ứng dụng Native riêng biệt.

CHƯƠNG 2. ỨNG DỤNG 1 - CHẨN ĐOÁN RỦI RO TIỂU ĐƯỜNG (Y TẾ)

2.1. Phân tích Dữ liệu Khám phá (EDA)

Tập dữ liệu y tế chứa các chỉ số sinh tồn và kết quả xét nghiệm máu (Glucose, HbA1c, BMI). Phân tích EDA cho thấy một thách thức nghiêm trọng: hiện tượng mất cân bằng dữ liệu (Imbalanced Data). Số lượng hồ sơ "Khỏe mạnh" áp đảo hoàn toàn số lượng hồ sơ "Có bệnh" (tỷ lệ khoảng 9:1). Nếu huấn luyện trực tiếp, mô hình sẽ có xu hướng dự đoán toàn bộ là "Khỏe mạnh" để đạt độ chính xác (Accuracy) giả tạo.

2.2. Kỹ thuật Tiền xử lý và Mô hình hóa

Để giải quyết bài toán này, kỹ thuật SMOTE (Synthetic Minority Over-sampling Technique) được áp dụng trong giai đoạn tiền xử lý. SMOTE không sao chép dữ liệu mù quáng mà tạo ra các điểm dữ liệu tổng hợp dựa trên nội suy từ các láng giềng gần nhất (K-Nearest Neighbors), giúp cân bằng ranh giới quyết định.

Thuật toán Random Forest Classifier được lựa chọn làm Final Model nhờ khả năng xử lý tốt dữ liệu phi tuyến tính và kháng nhiễu.

2.3. Đánh giá Mô hình (Evaluation)

Trong bài toán y tế, việc chẩn đoán sót bệnh nhân (False Negative) mang lại hậu quả nghiêm trọng hơn rất nhiều so với chẩn đoán nhầm người khỏe thành có bệnh (False Positive). Do đó, độ đo **Accuracy** bị loại bỏ. Hệ thống tập trung tối ưu hóa chỉ số **Recall** (Độ bao phủ) của lớp "Có bệnh", đảm bảo khả năng phát hiện tối đa các ca dương tính.

CHƯƠNG 3. ỨNG DỤNG 2 - ĐỊNH GIÁ BẤT ĐỘNG SẢN (TÀI CHÍNH)

3.1. Phân tích Dữ liệu và Xử lý Nhiễu (Outliers)

Giá nhà là một biến liên tục, chịu ảnh hưởng bởi nhiều yếu tố nhiễu (nhà siêu nhỏ, giá siêu cao do đầu cơ). Trong bước Data Preparation, phương pháp IQR (Interquartile Range) được sử dụng để cắt tỉa các điểm dữ liệu ngoại lai (Outliers), giúp mô hình không bị "kéo lệch" bởi các giao dịch bất thường.

3.2. Mô hình hóa với Random Forest Regressor

Bài toán hồi quy (Regression) yêu cầu dự đoán một giá trị liên tục. Random Forest Regressor hoạt động bằng cách xây dựng hàng trăm cây quyết định độc lập, sau đó lấy trung bình cộng (Averaging) kết quả dự đoán của tất cả các cây để ra mức giá cuối cùng, giúp giảm thiểu phương sai (Variance) và chống Overfitting.

3.3. Trích xuất Khoảng tin cậy (Confidence Interval)

Một điểm nhấn kỹ thuật của đồ án là không chỉ dự đoán một con số cứng nhắc. Bằng cách can thiệp vào tham số `estimators_` của mô hình `joblib` đã lưu, hệ thống trích xuất dự đoán từ toàn bộ 100 cây con, tính toán độ lệch chuẩn (Standard Deviation) bằng thư viện `Numpy`. Kết quả trả về cho người dùng là một "Khoảng giá dao động" (Ví dụ: 4.8 - 6.2 Tỷ VNĐ), mô phỏng chính xác cách thức hoạt động của các chuyên viên thẩm định giá thực tế.

CHƯƠNG 4. ỨNG DỤNG 3 - PHÂN TÍCH HÀNH VI E-COMMERCE (THƯƠNG MẠI)

4.1. Đặc trưng Dữ liệu

Tập dữ liệu E-commerce chứa nhiều biến phân loại (Categorical Variables) như Giới tính, Thành phố, Hạng thẻ thành viên. Kỹ thuật One-Hot Encoding được áp dụng để chuyển hóa các dữ liệu chữ này thành các vector không gian (0 và 1) để thuật toán có thể tính toán toán học.

4.2. Bài toán Phân loại Đa lớp (Multiclass Classification)

Mục tiêu là phân loại khách hàng vào 3 nhóm mức độ hài lòng (Satisfied, Neutral, Unsatisfied). Thay vì sử dụng Hồi quy Logistic đa thức, Random Forest tiếp tục cho thấy sự ưu việt trong việc tự động tìm ra các tổ hợp đặc trưng quan trọng (Feature Importance) như **Total Spend** (Tổng chi tiêu) hay **Days Since Last Purchase** (Số ngày từ lần mua cuối).

4.3. Đánh giá bằng Weighted F1-Score

Để đánh giá công bằng hiệu suất trên cả 3 lớp dữ liệu, chỉ số **Weighted F1-Score** được sử dụng thay vì Macro F1. Weighted F1 tính trung bình có trọng số dựa trên số lượng mẫu thực tế của từng nhóm, phản ánh đúng đắn hiệu suất tổng thể của mô hình.

CHƯƠNG 5. SO SÁNH CHÉO 3 ỨNG DỤNG (CROSS-APPLICATION COMPARISON)

Điểm cốt lõi của việc phát triển một hệ thống đa nhiệm (Multi-domain) không chỉ nằm ở việc xây dựng thành công các API, mà là sự thấu hiểu sâu sắc sự khác biệt về mặt bản chất toán học và cấu trúc dữ liệu của từng nghiệp vụ. Bảng dưới đây tổng hợp các khác biệt trọng yếu giữa 3 hệ thống:

Bảng so sánh tổng quan cấu trúc, biểu diễn, tiền xử lý và thước đo của 3 ứng dụng

Tiêu chí cốt lõi	App 1: Y tế (Tiểu đường)	App 2: Tài chính (Giá nhà)	App 3: Thương mại (E-commerce)
1. Cấu trúc dữ liệu	Dữ liệu dạng bảng tĩnh, mất cân bằng cực đại (Tỷ lệ lớp 0 và 1 lệch hẳn). Các biến chủ yếu là số thực (Sinh tồn, Xét nghiệm).	Dữ liệu dạng bảng động, chứa nhiều điểm ngoại lai (Outliers) do bong bóng thị trường. Đặc trưng phân loại phức tạp (Quận, Pháp lý).	Dữ liệu hành vi đa dạng. Chứa tổ hợp đan xen giữa biến liên tục (Chi tiêu) và biến phân loại nhiều cấp (Hạng thẻ, Thành phố).
2. Cách biểu diễn kết quả	Phân loại nhị phân (Binary): Biểu diễn dưới dạng nhãn 0/1 và xác suất % rủi ro mắc bệnh.	Hồi quy (Regression): Biểu diễn dưới dạng một con số liên tục (Tỷ VNĐ) kèm khoảng giá tin cậy.	Phân loại đa lớp (Multiclass): Biểu diễn dưới dạng 1 trong 3 nhãn phân biệt (Hài lòng / Bình thường / Không hài lòng).
3. Phương pháp Tiền xử lý	Nội suy dữ liệu, áp dụng SMOTE để over-sampling lớp thiểu số, cân bằng ranh giới toán học.	Cắt tía ngoại lai bằng IQR để làm sạch nhiễu. Dùng One-hot encoding ép khuôn các biến hạng mục.	Chú trọng xử lý tương quan đa cộng tuyến. Dùng kỹ thuật Encoding biến đổi các hạng mục thành không gian vector.
4. Thước đo đánh giá	Ưu tiên tuyệt đối Recall (Độ bao phủ) của lớp 1. Bỏ qua Accuracy.	Sử dụng RMSE (Căn bậc hai sai số toàn phương) và R-Squared.	Sử dụng Weighted F1-Score để đánh giá tổng hòa các lớp.

Phân tích chuyên sâu các điểm khác biệt

5.1. Khác biệt về Cấu trúc dữ liệu (Data Structure)

Ba tập dữ liệu đại diện cho ba hình thái dữ liệu đặc trưng trong thực tế:

- Dữ liệu Y tế có tính chất mất cân bằng cấu trúc (Structural Imbalance). Hồ sơ bệnh nhân mắc tiểu đường luôn chiếm thiểu số so với quần thể khỏe mạnh.

- Dữ liệu Bất động sản có cấu trúc phân tán có độ nhiễu cao (High-variance Distribution). Giá nhà không tuân theo phân phối chuẩn (Normal Distribution) mà thường bị kéo lệch (Skewed) bởi các giao dịch đột biến (nhà trong ngõ sâu hoặc biệt thự cao cấp).
- Dữ liệu E-commerce có cấu trúc ma trận hành vi (Behavioral Matrix), nơi các biến phân loại (Categorical) như hạng thẻ thành viên hay mã giảm giá chi phối mạnh mẽ đến quyết định cuối cùng, đòi hỏi thuật toán phải biết tìm ra các nút cắt (splits) mang lượng thông tin lớn nhất (Information Gain).

5.2. Khác biệt về Cách biểu diễn (Representation)

Cách hệ thống trả về (biểu diễn) kết quả phải tuân thủ đúng nghiệp vụ của bài toán:

- Với Y tế và Thương mại (Classification), đầu ra của mô hình Random Forest là một hàm xác suất phân phối **predict_proba()**. Việc biểu diễn không chỉ dừng ở nhãn cứng (Có/Không), mà phải hiển thị "Độ tự tin %" để bác sĩ hoặc nhân viên marketing biết mức độ rủi ro.
- Ngược lại, với Bất động sản (Regression), mô hình biểu diễn một giá trị liên tục. Đặc biệt, hệ thống đã can thiệp vào từng cây con (**estimators_**) trong rừng ngẫu nhiên để trích xuất phương sai, qua đó biểu diễn kết quả dưới dạng Khoảng giá (Confidence Interval) thay vì một điểm giá duy nhất. Đây là phương pháp biểu diễn mô phỏng chính xác tư duy thẩm định giá của ngân hàng.

5.3. Khác biệt về Phương pháp Tiền xử lý (Preprocessing)

- **Ứng dụng Y tế:** Nếu không can thiệp, mô hình sẽ bị "mù" với lớp có bệnh. Tiền xử lý ở đây mang tính chất "Kiến tạo" - sử dụng thuật toán SMOTE để sinh ra các điểm dữ liệu nội suy (Synthetic) giúp cân bằng không gian vector, thay vì sao chép thủ công dễ gây Overfitting.
- **Ứng dụng Bất động sản:** Tiền xử lý mang tính chất "Cắt tỉa". Phương pháp IQR (Interquartile Range) được sử dụng để chặt bỏ các phần tử dữ liệu ngoại lai, giúp các cây quyết định không bị kéo lệch trọng số.
- Điểm chung duy nhất trong tiền xử lý khi đưa lên Backend là cả 3 bài toán đều sử dụng kỹ thuật **.reindex()** thay thế cho việc lưu trữ đối tượng Scaler, nhằm đồng bộ số chiều của vector, phòng chống tuyệt đối rò rỉ dữ liệu (Data Leakage).

5.4. Sự khác nhau trong việc chọn Thước đo đánh giá (Evaluation Metrics)

Việc chọn sai thước đo sẽ dẫn đến một mô hình vô giá trị trong thực tiễn:

- **Vì sao Y tế chọn Recall?** Trong chẩn đoán bệnh, sai lầm False Negative (bỏ lọt người mang bệnh) có thể dẫn đến tử vong, trong khi False Positive (báo động nhầm) chỉ tốn thêm chi phí xét nghiệm lại. Do đó, Accuracy bị phớt lờ, hệ thống tập trung đẩy **Recall** của lớp dương tính lên mức cao nhất.

- **Vì sao Bất động sản chọn RMSE?** Việc định giá cần đo lường được bằng tiền thật. Khoảng cách (Error) giữa dự đoán và thực tế càng lớn thì hệ thống càng tệ. RMSE phạt rất nặng các sai số lớn, buộc mô hình phải bám sát giá trị giao dịch thực.
- **Vì sao E-commerce chọn Weighted F1-Score?** Khách hàng chia làm 3 nhóm không đều nhau. Nếu dùng F1 Macro, các nhóm sẽ bị tính trung bình cào bằng. Kỹ thuật **Weighted F1** sẽ nhân trọng số tỷ lệ thuận với số lượng mẫu thực tế của từng nhóm (Satisfied, Neutral, Unsatisfied), giúp đánh giá mô hình một cách công tâm và toàn diện nhất.

CHƯƠNG 6. KỸ THUẬT TRIỂN KHAI VÀ XAI (EXPLAINABLE AI)

6.1. Ngăn chặn Rò rỉ Dữ liệu (Data Leakage Prevention)

Rò rỉ dữ liệu (Data Leakage) là lỗi nghiêm trọng nhất khi đưa mô hình học máy vào thực tế (Production). Lỗi này xảy ra khi Pipeline tiền xử lý bị "fit" lại (học lại) dựa trên dữ liệu đầu vào của người dùng, làm thay đổi cấu trúc không gian toán học. Hệ thống này xử lý triệt để rủi ro trên bằng kỹ thuật **Data Alignment**. Khi nhận JSON đầu vào qua API, hệ thống biến đổi thành DataFrame và sử dụng hàm **.reindex(columns=saved_columns, fill_value=0)**. Cơ chế này hoạt động như một "cái khuôn":

Cắt bỏ mọi đặc trưng rác (các cột lạ không có trong tập Train).

Tự động điền giá trị 0 cho các đặc trưng thiếu khuyết. Đảm bảo mảng vector đưa vào hàm **.predict()** luôn khớp 100% với cấu trúc đã được huấn luyện mà không cần gọi lại đối tượng Encoder.

6.2. Suy luận dựa trên ca mẫu (Case-based Reasoning) & XAI


Để khắc phục nhược điểm "hộp đen" (Black-box) của thuật toán học máy, đồ án áp dụng tư tưởng Explainable AI thông qua phương pháp Case-based Reasoning. Bên cạnh việc trả về dự đoán của AI, Backend được lập trình để nạp tập dữ liệu gốc (CSV) vào RAM. Khi nhận request, hệ thống sử dụng thuật toán lọc của **Pandas** để quét và trích xuất top 3 hồ sơ trong quá khứ có các đặc điểm (Tuổi, Hạng thẻ, Khu vực) tương đồng nhất với đầu vào hiện tại. Việc hiển thị dữ liệu lịch sử này giúp người dùng cuối hiểu được tính logic và cơ sở tham chiếu của quyết định AI.

6.3. Triển khai Giao diện và Demo Đa nền tảng (Responsive UI)

Hệ thống được phát triển với giao diện người dùng (Frontend) tách biệt hoàn toàn với máy chủ xử lý (Backend API). Giao diện sử dụng Grid System của Bootstrap 5, đảm bảo khả năng hiển thị tương thích (Responsive) trên cả màn hình máy tính và thiết bị di động mà không cần phát triển ứng dụng Native riêng biệt.


1. ỨNG DỤNG 1 - CHẨN ĐOÁN RỦI RO TIỂU ĐƯỜNG (Y TẾ)

Triển khai	Nhập dữ liệu đầu vào	Kết quả dự đoán
------------	----------------------	-----------------

Web		 <table><thead><tr><th colspan="3">Các trường hợp tương tự trong lịch sử:</th></tr><tr><th>Khu vực</th><th>Diện tích</th><th>Loại</th></tr></thead><tbody><tr><td>Quận Hoàn Kiếm</td><td>165 m²</td><td>Nhà mặt phố, mặt tiền</td></tr><tr><td>Quận Hoàn Kiếm</td><td>20 m²</td><td>Nhà mặt phố, mặt tiền</td></tr><tr><td>Quận Hoàn Kiếm</td><td>38 m²</td><td>Nhà mặt phố, mặt tiền</td></tr></tbody></table>	Các trường hợp tương tự trong lịch sử:			Khu vực	Diện tích	Loại	Quận Hoàn Kiếm	165 m²	Nhà mặt phố, mặt tiền	Quận Hoàn Kiếm	20 m²	Nhà mặt phố, mặt tiền	Quận Hoàn Kiếm	38 m²	Nhà mặt phố, mặt tiền
Các trường hợp tương tự trong lịch sử:																	
Khu vực	Diện tích	Loại															
Quận Hoàn Kiếm	165 m²	Nhà mặt phố, mặt tiền															
Quận Hoàn Kiếm	20 m²	Nhà mặt phố, mặt tiền															
Quận Hoàn Kiếm	38 m²	Nhà mặt phố, mặt tiền															
Mobile		 <table><thead><tr><th colspan="3">Các trường hợp tương tự trong lịch sử:</th></tr><tr><th>Khu vực</th><th>Diện tích</th><th>Loại</th></tr></thead><tbody><tr><td>Quận Cầu Giấy</td><td>46 m²</td><td>Nhà ngõ, hẻm</td></tr><tr><td>Quận Cầu Giấy</td><td>46 m²</td><td>Nhà ngõ, hẻm</td></tr><tr><td>Quận Cầu Giấy</td><td>45 m²</td><td>Nhà ngõ, hẻm</td></tr></tbody></table>	Các trường hợp tương tự trong lịch sử:			Khu vực	Diện tích	Loại	Quận Cầu Giấy	46 m²	Nhà ngõ, hẻm	Quận Cầu Giấy	46 m²	Nhà ngõ, hẻm	Quận Cầu Giấy	45 m²	Nhà ngõ, hẻm
Các trường hợp tương tự trong lịch sử:																	
Khu vực	Diện tích	Loại															
Quận Cầu Giấy	46 m²	Nhà ngõ, hẻm															
Quận Cầu Giấy	46 m²	Nhà ngõ, hẻm															
Quận Cầu Giấy	45 m²	Nhà ngõ, hẻm															

3. ỨNG DỤNG 3 - PHÂN TÍCH HÀNH VI E-COMMERCE (THƯƠNG MẠI)

Triển khai	Nhập dữ liệu đầu vào	Kết quả dự đoán
------------	----------------------	-----------------



6.4. Quản lý Mã nguồn (Source Code)

Toàn bộ quy trình từ khâu Tiền xử lý dữ liệu, Huấn luyện mô hình (Jupyter Notebooks) đến mã nguồn Triển khai hệ thống (FastAPI, HTML/JS) đều được quản lý phiên bản và công khai mã nguồn mở.

Kho mã nguồn (GitHub Repository): [namnguyen05-vn/PTHTTM_Assignment-02](https://github.com/namnguyen05-vn/PTHTTM_Assignment-02)

Cấu trúc nộp bài: Bao gồm file Báo cáo tổng quan, Phụ lục chi tiết quá trình huấn luyện và gói phần mềm hoàn chỉnh có đính kèm tài liệu hướng dẫn vận hành (README.md).

